Relatório de análise imobiliária

INTRODUÇÃO

Este relatório apresenta uma Análise Exploratória de Dados (EDA) de um banco de dados imobiliário com o objetivo de identificar padrões, tendências e insights que possam orientar os melhores locais para investimento de novos imóveis. A base de dados utilizada contém informações detalhadas de anúncios de diversas casas e apartamentos, incluindo bairro, valores e tipo de oferta, entre outros.

A análise exploratória de dados é uma etapa crucial no processo de análise de dados, pois permite compreender melhor as características e a estrutura do conjunto de dados, além de identificar possíveis problemas, *outliers* e relacionamentos entre variáveis. Através da utilização de técnicas estatísticas e de visualização de dados, este relatório visa fornecer uma visão abrangente das possibilidades existentes no que diz respeito à compra e aluguel de imóveis. As conclusões desta análise serão fundamentais para orientar decisões estratégicas para o ramo imobiliário local.

A base de dados fornecida possui mais de 48000 entradas com informações pertinentes para esse estudo. Porém, algumas das entradas possuem dados ausentes ou com informações que poderiam ser prejudiciais para a análise. Para obter melhores resultados, foram excluídas as linhas cujas informações não foram encontradas, reduzindo o número de objetos e seus dados analisados caíram para a metade. As variáveis existentes na base de dados são:

- *id* – Atua como uma chave exclusiva para cada anúncio nos dados do aplicativo;
- *nome* - Representa o nome do anúncio;
- *host_id* - Representa o id do usuário que hospedou o anúncio;
- *host_name* – Contém o nome do usuário que hospedou o anúncio;
- *bairro_group* - Contém o nome do bairro onde o anúncio está localizado;
- *bairro* - Contém o nome da área onde o anúncio está localizado;
- *latitude* - Contém a latitude do local;
- *longitude* - Contém a longitude do local;
- *room_type* – Contém o tipo de espaço de cada anúncio;
- *price* - Contém o preço por noite em dólares listado pelo anfitrião;
- *minimo_noites* - Contém o número mínimo de noites que o usuário deve reservar;
- *numero_de_reviews* - Contém o número de comentários dados a cada listagem;
- *ultima_review* - Contém a data da última revisão dada à listagem;
- *reviews_por_mes* - Contém o número de avaliações fornecidas por mês;
- *calculado_host_listings_count* - Contém a quantidade de listagem por host;
- *disponibilidade_365* - Contém o número de dias em que o anúncio está disponível para reserva.

ANÁLISE EXPLORATÓRIA DE DADOS

Antes da análise exploratória de dados, foi feita a verificação das informações fornecidas no *dataset* disponibilizado e com isso algumas ações foram tomadas. A primeira foi a exclusão das colunas *host_id*, *host_name*, *ultima_review* e *calculado_host_listing_count*, pois elas não apresentavam informações consideradas relevantes para o desenvolvimento do EDA. As linhas onde o valor de *price* estava zerado ou em branco também foram excluídas, assim como as linhas onde o valor de *disponibilidade_365* também estava zerado, pois indicava que o local não estava disponível.

	id	latitude	longitude	price	minimo_noites	numero_de_reviews	reviews_por_mes	disponibilidade_365
count	3.135300e+04	31353.000000	31353.000000	31353.000000	31353.000000	31353.000000	26146.000000	31353.000000
mean	2.100560e+07	40.728409	-73.948752	162.092240	8.338660	31.850094	1.810124	175.828406
std	1.148734e+07	0.056561	0.051400	254.448797	23.839305	51.639221	1.805664	126.192864
min	2.595000e+03	40.499790	-74.244420	10.000000	1.000000	0.000000	0.010000	1.000000
25%	1.167431e+07	40.688400	-73.983280	70.000000	2.000000	2.000000	0.450000	55.000000
50%	2.256150e+07	40.723730	-73.954110	112.000000	3.000000	10.000000	1.230000	168.000000
75%	3.119458e+07	40.763040	-73.930150	189.000000	5.000000	39.000000	2.680000	305.000000
max	3.648724e+07	40.913060	-73.712990	10000.000000	1250.000000	629.000000	58.500000	365.000000

Imagem 01 - Resultados encontrados com o método *describe*

O primeiro tópico da análise exploratória de dados foi entender como os valores eram oferecidos nos anúncios. Destacou-se a quantidade de alugueis mais acessíveis nas ofertas encontradas.

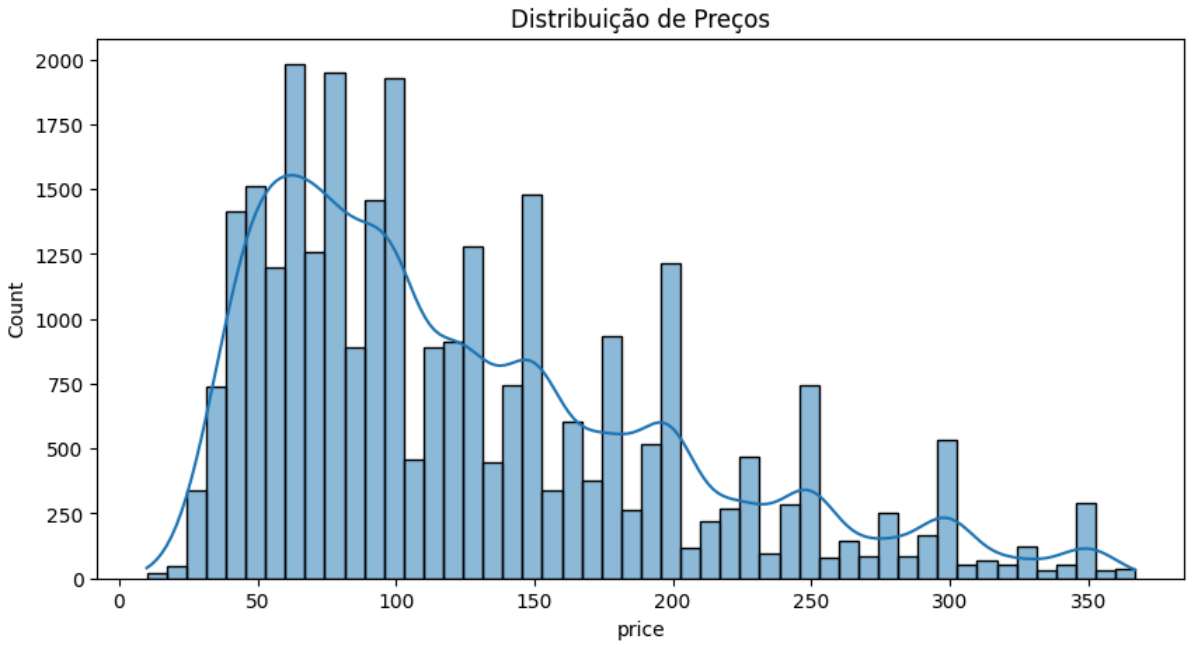

Imagem 02 - Gráfico que mostra a distribuição dos preços

Em seguida, foi feita a verificação dos *outliers* e sua exclusão, buscando evitar ruídos nos resultados. Os *outliers* são valores que fogem ao que é tido como média entre os valores e isso pode acabar alterando consideravelmente a previsão futura de dados.

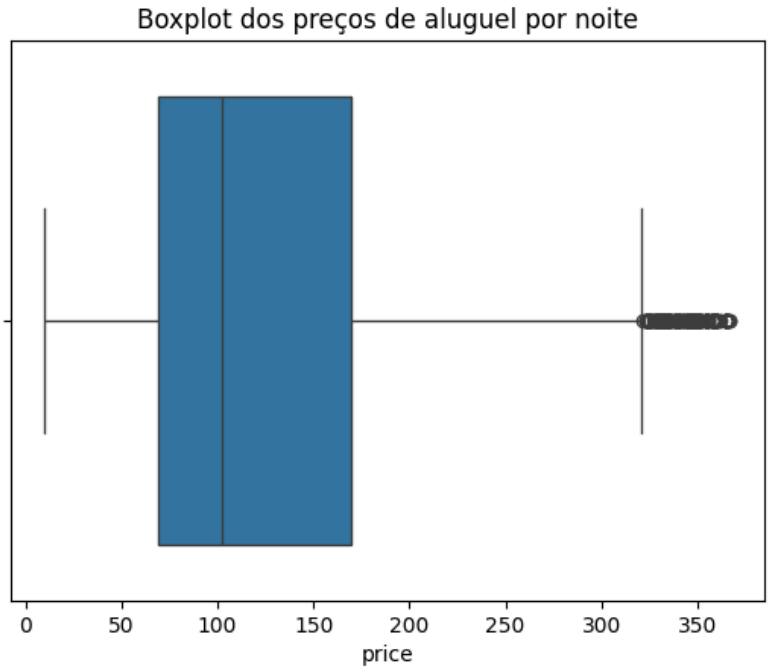

Imagem 03 - Análise dos preços de aluguel após outliers

Após a análise dos preços, foi verificada a localização dos imóveis, para entender se existe algum padrão geográfico presente que possa ser levado em consideração. Algumas regiões apresentaram grande número de anúncios, enquanto em outras regiões, as ofertas eram mais dispersas.

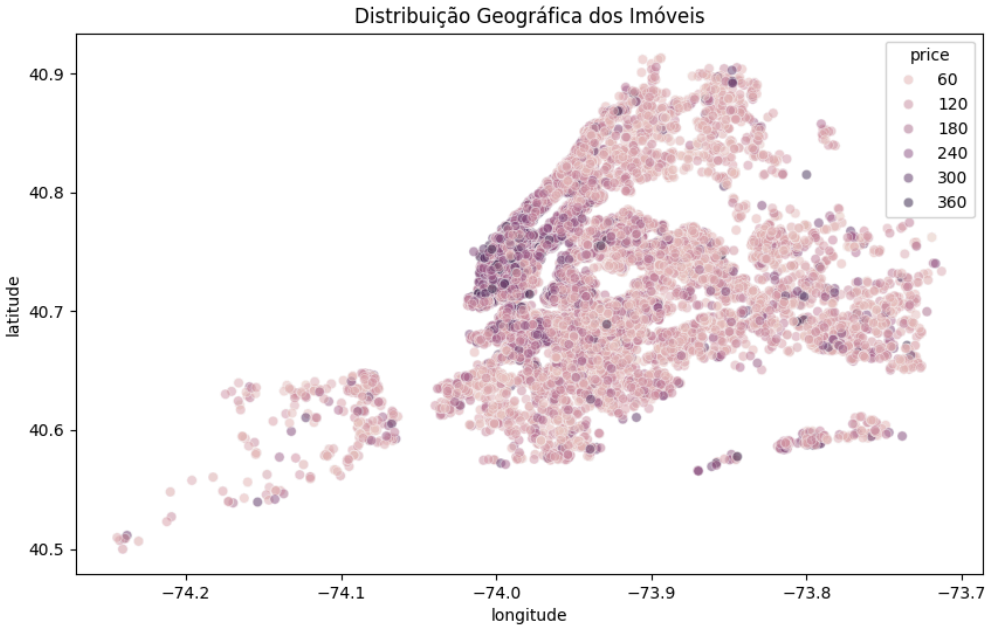

Imagem 04 - Distribuição geográfica dos anúncios

Essa verificação geográfica também permitiu entender em quais bairros havia maiores ofertas. Cinco bairros foram analisados e as variações entre eles estavam entre 10 a 40 mil anúncios, sendo a maior concentração em Manhattan e a menor no Bronx.

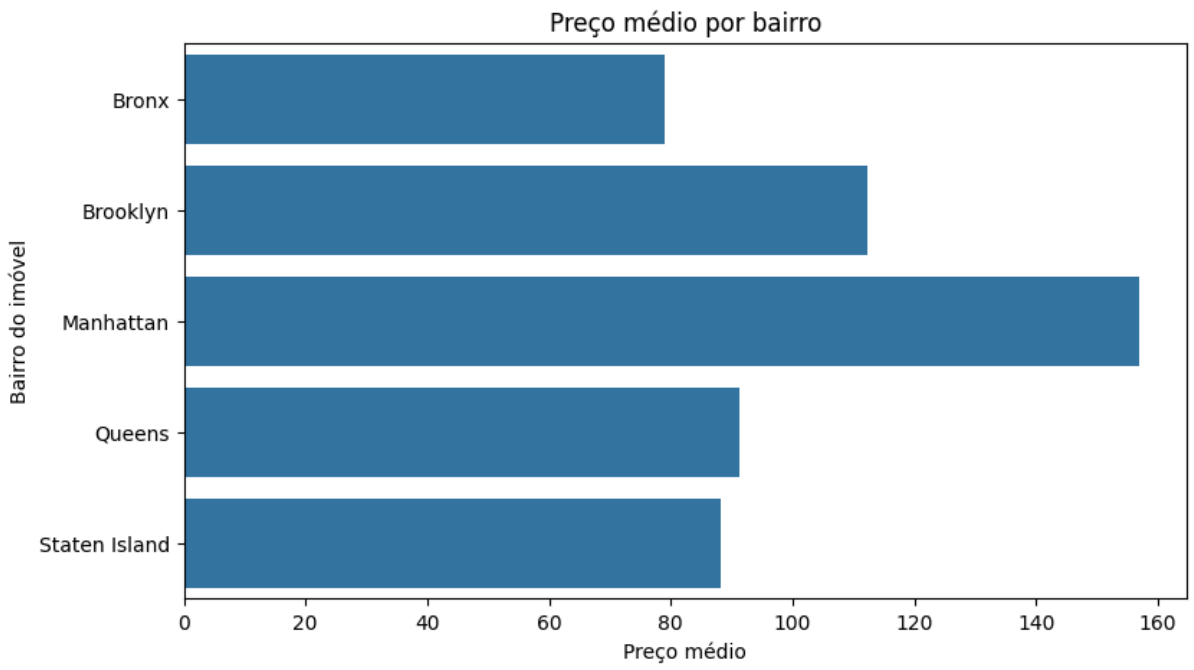

Imagem 05 - Análise da quantidade de anúncios por bairro

Outro fator cuja relação foi analisada em relação ao preço foi a tipologia do anúncio. Eles se dividiram em três categorias e foi verificado como os preços estavam distribuídos entre elas. Vale ressaltar que foram encontrados *outliers* por categoria, porém isso não afetou o resultado final deste estudo.

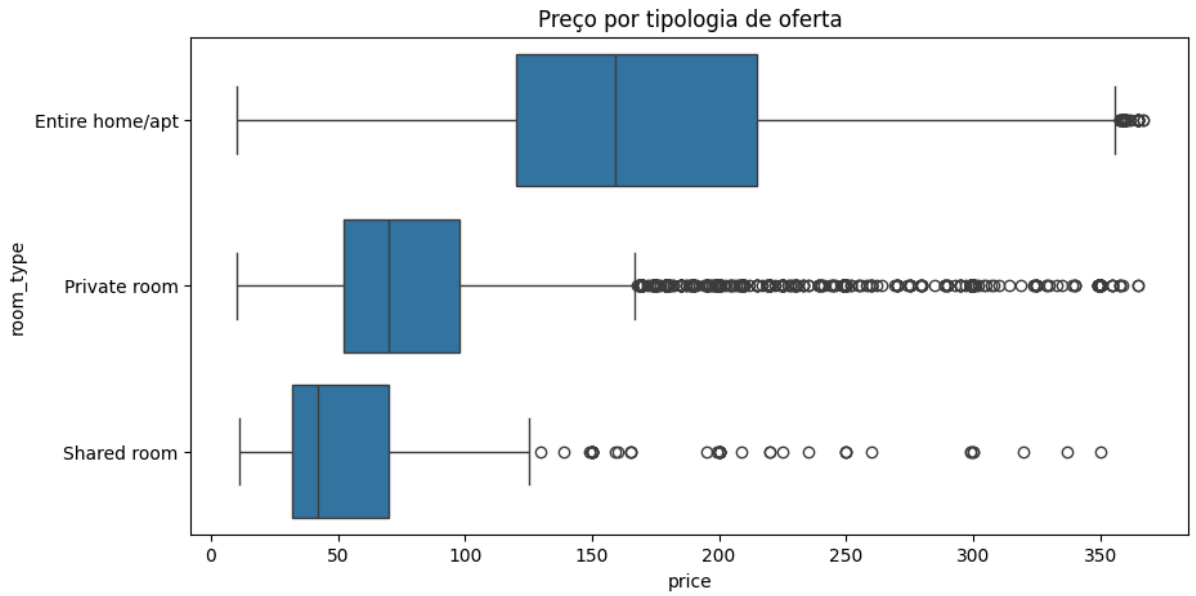

Imagem 06 - Análise dos preços por tipologia de oferta

Foram verificados se haviam padrões de uso em relação a disponibilidade e o tempo de estadia nos locais ofertados. Ficou evidente que a variável *disponibilidade_365* não possui tamanha relevância quando analisada isoladamente, pois os valores apresentados estão bem dispersos pelo intervalo de quantidade de dias disponíveis.

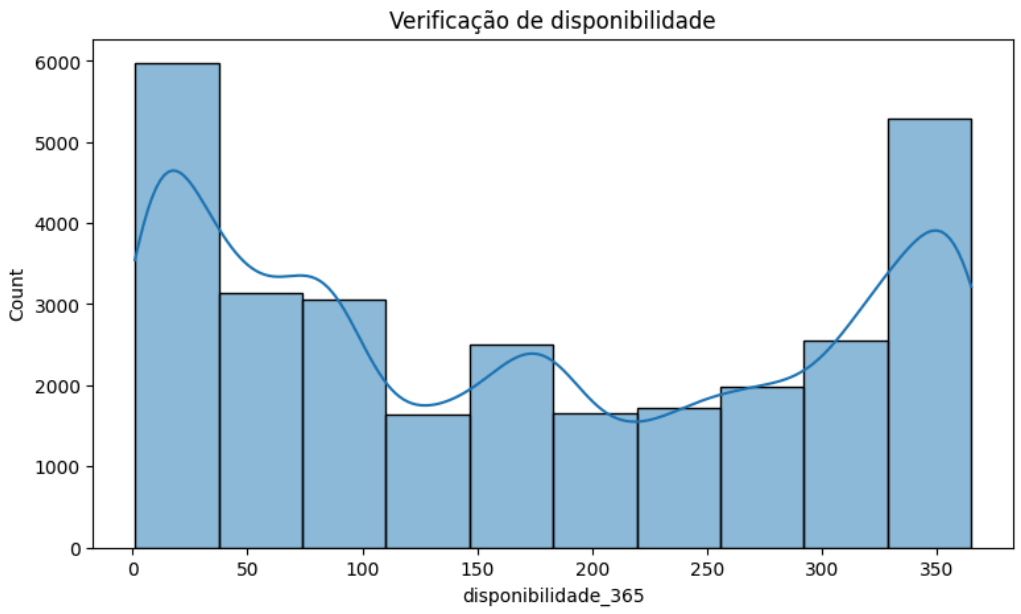

Imagem 07 - Análise da frequência de datas disponíveis

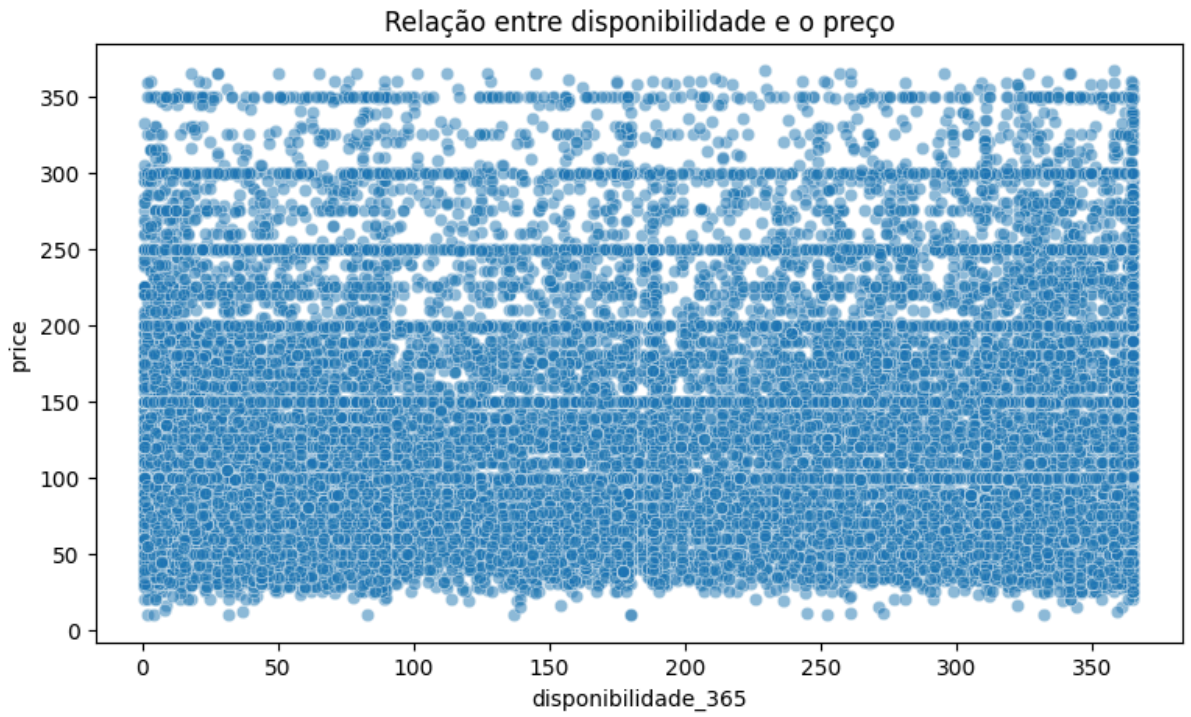

Imagem 08 - Análise dos preços em relação a disponibilidade dos locais

Em relação a variável *minimo_noites*, percebe-se que a quantidade mínima dos itens analisados se concentram no lado esquerdo do gráfico, com pouquíssimos anúncios tendo grandes quantidades nesse quesito. Ao analisar a relação da variável com os valores, é perceptível que os valores estão bem distribuídos.

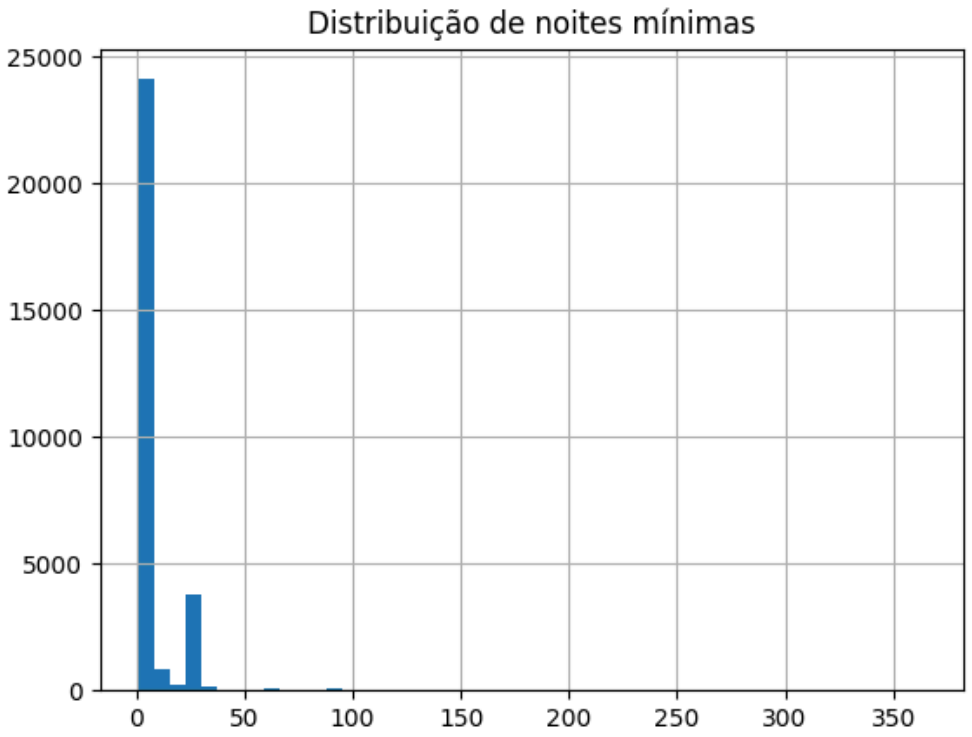

Imagem 10 - Gráfico da distribuição da quantidade mínima de noites

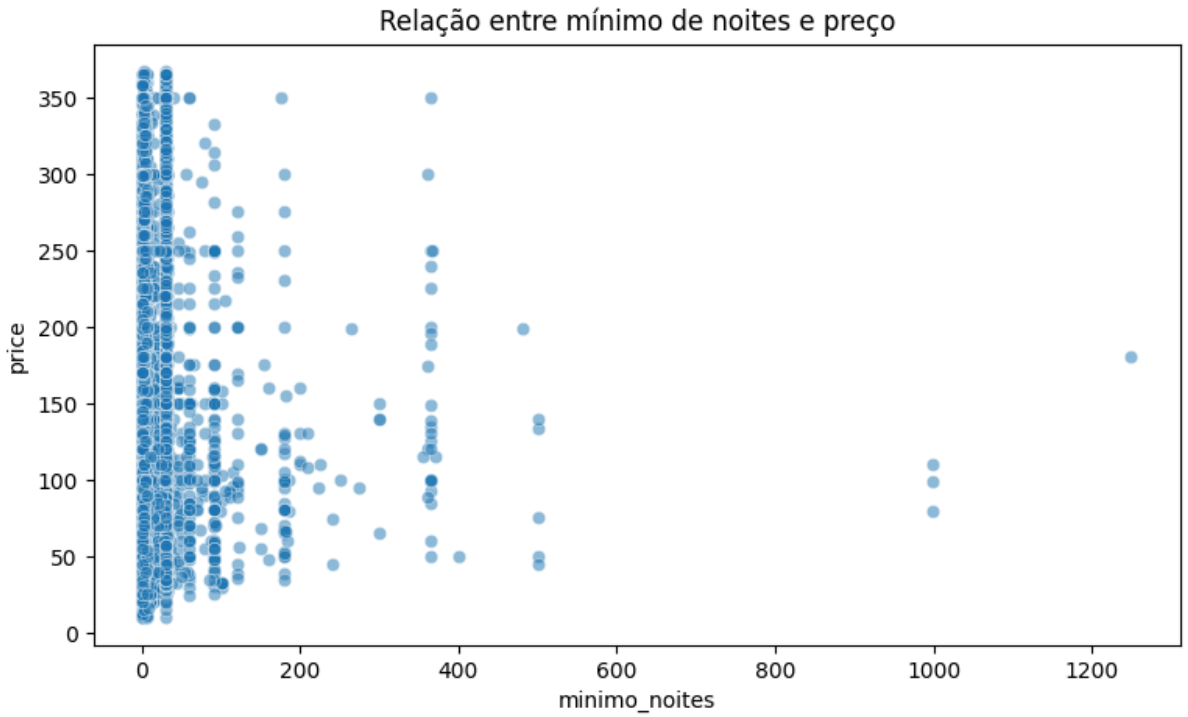

Imagem 11 - Análise dos preços em relação ao número mínimo de noites por anúncio

Com isso, é possível afirmar que as duas últimas categorias citadas não apresentam maior relevância se analisadas de maneira isolada, porém, ao serem analisadas em conjunto com outras variáveis podem demonstrar maior importância para a previsão de novos valores.

Também foi analisada de que forma a quantidade de reviews, seja no total ou por mês, deve ser levada em consideração para o desenvolvimento futuro do modelo. Em relação às quantidades, o gráfico mostra uma curva decrescente, com muitos anúncios possuindo poucos comentários. Em relação ao valor, o gráfico está bem disperso no que diz respeito a essa distribuição. Isso nos leva a crer que essas categorias também devem ser analisadas em conjunto para obter melhores resultados.

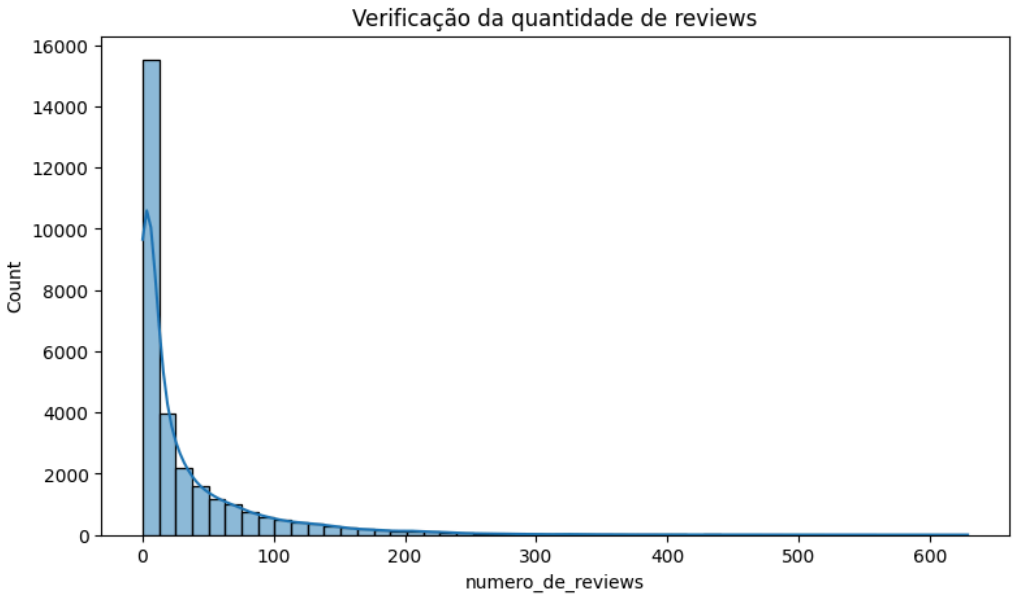

Imagem 12 - Gráfico exibindo a quantidade de reviews

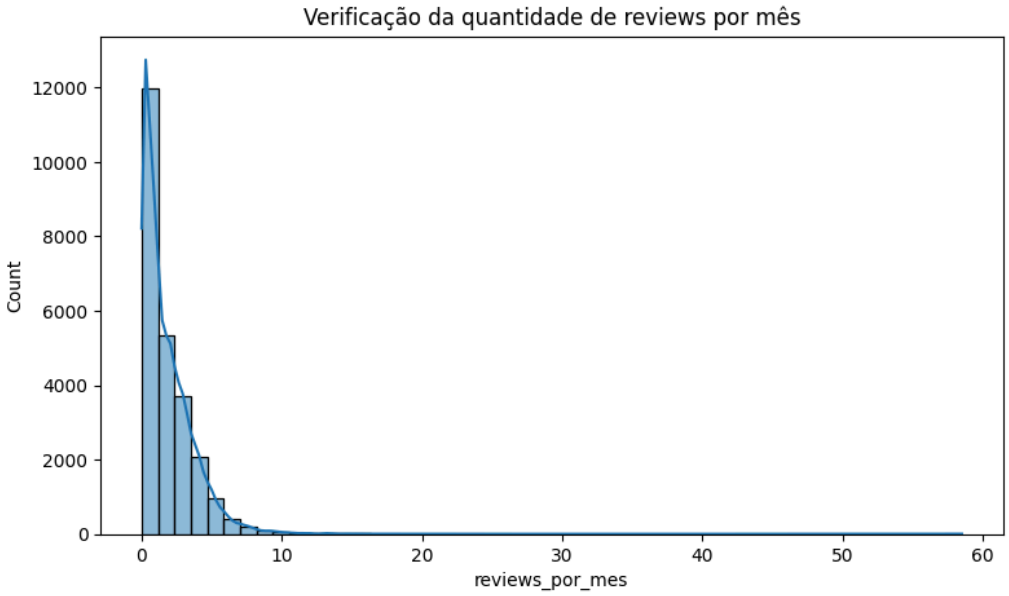

Imagem 13 - Gráfico que exibe a quantidade de reviews por mês

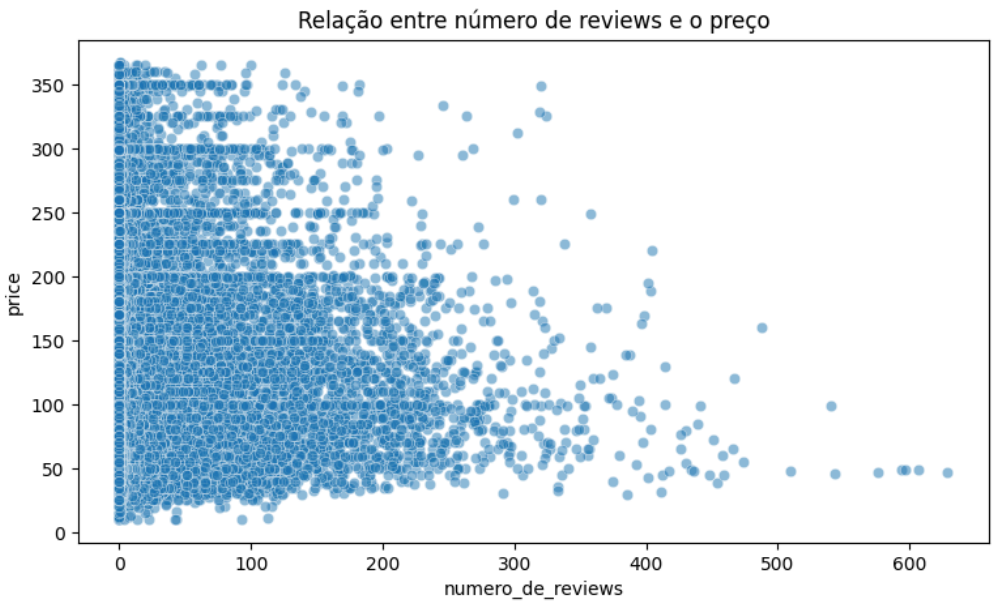

Imagem 14 - Análise dos preços em relação ao número de reviews

QUESTIONAMENTOS COMPLEMENTARES

Alguns questionamentos extras foram feitos como parte deste desafio. Todos são pertinentes à temática de dados e muitos deles estão diretamente relacionados com a análise exploratória feita acima.

1. Explique como você faria a previsão do <u>preço</u> a partir dos dados. Quais variáveis e/ou suas transformações você utilizou e por quê? Qual tipo de problema estamos resolvendo (regressão, classificação)? Qual modelo melhor se aproxima dos dados e quais seus prós e contras? Qual medida de performance do modelo foi escolhida e por quê?

Para a solução deste caso, foram utilizadas boa parte das informações disponíveis. As variáveis que representavam dados no morador (*host_id*, *host_name*, *calculado_host_listings_count*) foram descartados por não apresentarem relevância para o estudo. Além dessa, a variável *ultima_review* também foi desconsiderada pois apresentava grande quantidade de dados ausentes.

Após a análise exploratória de dados, foram desconsideradas as demais linhas que não apresentavam itens considerados relevantes para o desenvolvimento do modelo. As variáveis *bairro*, *bairro_group* e *room_type* foram transformadas para poderem ser usadas. Na primeira, foi feita a transformação utilizando *Label Encoder*, devido a grande quantidade de valores diferentes nela. As outras duas sofreram transformação do tipo *One-Hot Encoder*, utilizada quando os itens possuem uma pequena e/ou razoável quantidade de variações (*room_type* possui três e *bairro_group* possui cinco).

Este tipo de problema pede que seja feita uma **Regressão Linear**, considerando que estamos analisando uma variável que pode ser considerada como contínua. Essa regressão é

supervisionada pois nossos dados são rotulados e o desafio pede que seja fornecida uma saída para um dado de entrada.

Para isso, o modelo implementado foi o de **Random Forests**. Mesmo podendo ser um modelo não tão rápido, ele acaba sendo mais preciso do que uma simples *Decision Tree* e não precisa de muitos ajustes para ser executado. A hiperparametrização foi ajustada utilizando **RandomizedSearchCV**, considerando que essa é a escolha mais eficiente quando estamos trabalhando com uma base de dados robusta.

A medida de performance escolhida aqui foi **Root Mean Squared Error (RMSE ou Raiz do Erro Quadrado Médio)**. Essa medida está diretamente ligada a modelos de regressão. Outro motivo para escolha deste tipo de performance aconteceu devido a exclusão de dados com outliers, o que faz com que não seja necessário executar o *erro absoluto médio (MAE)*.

2. Supondo que uma pessoa esteja pensando em investir em um apartamento para alugar na plataforma, onde seria mais indicada a compra?

Ao fazer o agrupamento das informações fornecidas nas variáveis *bairro_group* e *price* e verificar a média dos valores por cada grupo, é possível indicar a compra de imóveis nos bairros de Manhattan e Brooklyn, já que ambos possuem as maiores médias de valores dentre os grupos analisados.

3. O número mínimo de noites e a disponibilidade ao longo do ano interferem no preço?

Sim e não. Ambos os itens podem influenciar no preço do local, mas tal interferência pode acontecer de forma mais forte se aliados com outras variáveis, como por exemplo a localização do imóvel. Analisados de maneira isolada, não demonstram extrema relevância para a determinação do valor.

4. Existe algum padrão no texto do nome do local para lugares de mais alto valor?

Praticamente todos os termos de destaque utilizados na nomenclatura dos locais são encontrados tanto nos locais mais caros como nos mais baratos. Termos como *studio*, *east* e *park* foram encontrados apenas na busca pelos lugares mais caros, o que é justificável considerando que ambos os termos apresentam ligação com as áreas mais ricas da cidade. Entretanto, temos como *near*, é encontrado com grande frequência nos itens mais baratos, indicando a proximidade de áreas relevantes da cidade, mas não estando nelas. Sendo assim, podemos concluir que não há um padrão evidente na nomenclatura dos imóveis que se relacione com seu valor de aluguel.

5. Supondo um apartamento com as seguintes características:

```
{
 'id': 2595,
 'nome': 'Skylit Midtown Castle',
 'host_id': 2845,
 'host_name': 'Jennifer',
 'bairro_group': 'Manhattan',
 'bairro': 'Midtown',
 'latitude': 40.75362,
 'longitude': -73.98377,
 'room_type': 'Entire home/apt',
 'minimo_noites': 1,
```

```
 'numero_de_reviews': 45,
 'ultima_review': '2019-05-21',
 'reviews_por_mes': 0.38,
 'calculado_host_listings_count': 2,
 'disponibilidade_365': 355
}
```

Qual seria a sua sugestão de preço?

Aplicando o modelo de *machine learning* pensado para este desafio, o valor aproximado de aluguel do imóvel seria de R$198,96.

CONCLUSÃO

A Análise Exploratória de Dados (EDA) realizada sobre o banco de dados fornecido proporcionou insights valiosos sobre diversos aspectos do mercado imobiliário da cidade de Nova York. Através do exame detalhado de variáveis como localização, tipologia do local, análises dos visitantes e prazos de estadia, foi possível identificar padrões, tendências e fatores que influenciam o valor de aluguel destes locais.

Os insights obtidos através deste relatório podem orientar decisões estratégicas em várias frentes, incluindo a escolha de imóveis para investimentos e o melhor formato na qual o imóvel em questão será alugado. A compreensão das variáveis analisadas é crucial para entender como está o mercado nova-iorquino em busca de melhores retornos financeiros.

Recomenda-se, para projetos futuros, a continuidade da análise com dados adicionais e o uso de técnicas mais avançadas, para aprofundar ainda mais a compreensão dos fatores que influenciam a determinação de valores dos alugueis de quartos e residências. A integração de feedback contínuo e dados em tempo real pode também aprimorar a precisão das previsões e a eficácia das estratégias adotadas.

A análise exploratória feita aqui é um passo fundamental no entendimento dos dados e na formulação de estratégias informadas. O mercado imobiliário de Nova York está sempre aquecido devido ao fator turístico e alta densidade populacional, portanto, utilizar dados de forma eficaz pode ser um diferencial significativo para o investimento.