Relatório PProductions

INTRODUÇÃO

Este relatório apresenta uma Análise Exploratória de Dados (EDA) de um banco de dados cinematográfico com o objetivo de identificar padrões, tendências e insights que possam orientar o desenvolvimento e a estratégia de marketing de novos filmes. A base de dados utilizada contém informações detalhadas sobre diversos filmes, incluindo título, ano de lançamento, classificação etária, tempo de duração, gêneros, avaliações no IMDb, sinopse, média ponderada de críticas, diretor, elenco principal, número de votos e faturamento.

É importante salientar que a base de dados fornecida não possui qualquer informação sobre público alvo, o que pode vir a influenciar a precisão da análise. Recomendaria à *PProductions* um estudo sobre o público alvo pretendido, considerando faixa etária do público e classificação etária do filme, além de tendências de hábitos, cultura e consumo audiovisual. Dessa forma, conseguimos uma análise mais robusta e precisa, aumentando também a probabilidade de um alto faturamento de retorno.

A análise exploratória de dados é uma etapa crucial no processo de análise de dados, pois permite compreender melhor as características e a estrutura do conjunto de dados, além de identificar possíveis problemas, outliers e relacionamentos entre variáveis. Através da utilização de técnicas estatísticas e de visualização de dados, este relatório visa fornecer uma visão abrangente do desempenho dos filmes e dos fatores que contribuem para o seu sucesso. As conclusões desta análise serão fundamentais para orientar decisões estratégicas no desenvolvimento de novos projetos cinematográficos e no aprimoramento das estratégias de lançamento e marketing.

A base de dados fornecida possui 1000 entradas com informações pertinentes para esse estudo. Porém, algumas das entradas possuem dados ausentes. Para obter melhores resultados, foram excluídas as linhas cujas informações não foram encontradas, reduzindo o número de objetos e seus dados analisados de 1000 para 713. As variáveis existentes na base de dados são:

- *Series_Title* – Nome do filme
- *Released_Year* - Ano de lançamento
- *Certificate* - Classificação etária

- *Runtime* – Tempo de duração
- *Genre* - Gênero
- *IMDB_Rating* - Nota do IMDB
- *Overview* - Overview do filme
- *Meta_score* - Média ponderada de todas as críticas
- *Director* – Diretor
- *Star1* - Ator/atriz #1
- *Star2* - Ator/atriz #2
- *Star3* - Ator/atriz #3
- *Star4* - Ator/atriz #4
- *No_of_Votes* - Número de votos
- *Gross* - Faturamento

ANÁLISE EXPLORATÓRIA DE DADOS

Para a análise exploratória dos dados, a coluna *Gross*, foi transformada para que seus dados fossem lidos como valores numéricos. Os valores de média, mediana e moda das variáveis numéricas não mostraram grandes oscilações entre eles. *IMDB_Rating* apresentou valores praticamente iguais de média e mediana, se diferenciando apenas no valor da moda em dois décimos a menos. *Meta_score* possui média variando em um ponto a mais para a mediana e um a menos para a moda. *No_of_Votes* e *Gross* mostravam maiores variações devido a grande diferença entre os dados apresentados, que possuíam, em alguns casos, diferenças entre mais de 10 a 100 mil unidades.

	Unnamed: 0	IMDB_Rating	Meta_score	No_of_Votes	Gross
count	713.000000	713.000000	713.000000	7.130000e+02	7.130000e+02
mean	519.300140	7.935203	77.154278	3.533480e+05	7.858395e+07
std	295.416331	0.288999	12.409392	3.462212e+05	1.150433e+08
min	1.000000	7.600000	28.000000	2.522900e+04	1.305000e+03
25%	263.000000	7.700000	70.000000	9.582600e+04	6.153939e+06
50%	527.000000	7.900000	78.000000	2.363110e+05	3.500000e+07
75%	778.000000	8.100000	86.000000	5.059180e+05	1.025158e+08
max	997.000000	9.200000	100.000000	2.303232e+06	9.366622e+08

Imagem 01 - Resultados encontrados com o método *describe*

```
IMDB_Rating: Mediana - 7.9 , Moda - 7.7
Meta_score: Mediana - 78.0 , Moda - 76.0
No_of_Votes: Mediana - 236311.0 , Moda - 25229
Gross: Mediana - 35000000.0 , Moda - 4360000.0
```

Imagem 02 - Resultado de mediana e moda das variáveis numéricas

O próximo passo foi analisar a correlação entre as colunas. A análise entre as variáveis categóricas não mostrou resultados relevantes. Entre as variáveis numéricas, duas apresentaram pontos relevantes, mesmo que de forma moderada:

- *No_of_Votes* e *IMDB_Rating* (0.609239): Filmes com mais votos tendem a ter classificações mais altas no IMDB;
- *No_of_Votes* e *Gross* (0.560955): Filmes com mais votos também tendem a ter uma maior receita bruta.

Na análise de outliers, três colunas se destacaram: *IMDB_Rating*, *No_of_Votes* e *Gross*. Na primeira, filmes com avaliação acima de 8.8 são considerados *outliers*, ou seja, valores atípicos que se diferem da maioria dos dados apresentados. As duas seguintes mostraram grandes variações, mostrando que os valores altos podem atrapalhar as análises.

Ao gerar histogramas básicos de avaliações de IMDB e *Metascore*, percebemos que a maioria dos dados se encontra em um determinado intervalo. No caso da primeira variável, a maioria das avaliações se encontram no intervalo entre 7,6 e 8,1. Já na segunda variável citada, a maioria das avaliações estão entre 75 a 85 pontos.

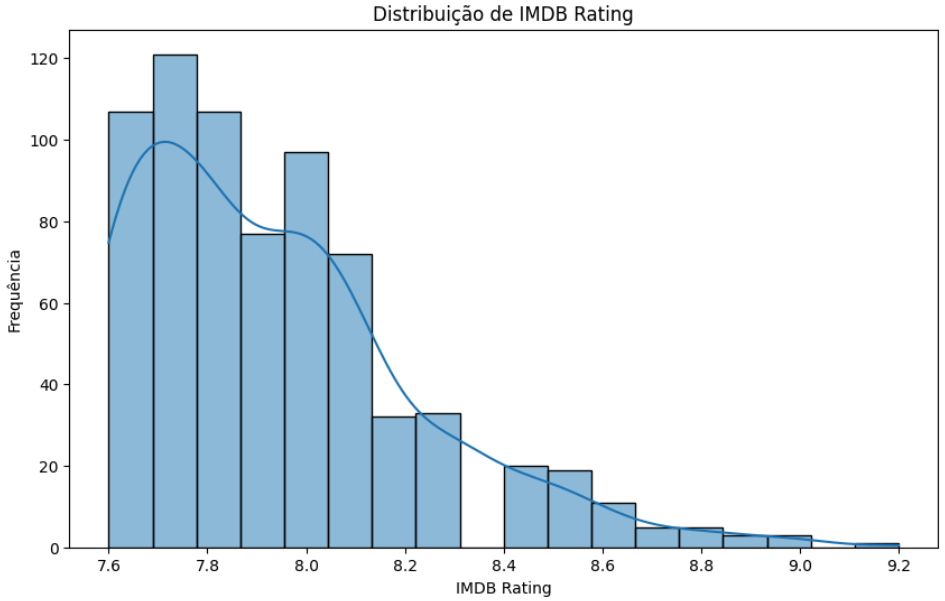

Imagem 03 - Gráfico que mostra a frequência das avaliações no IMDB.

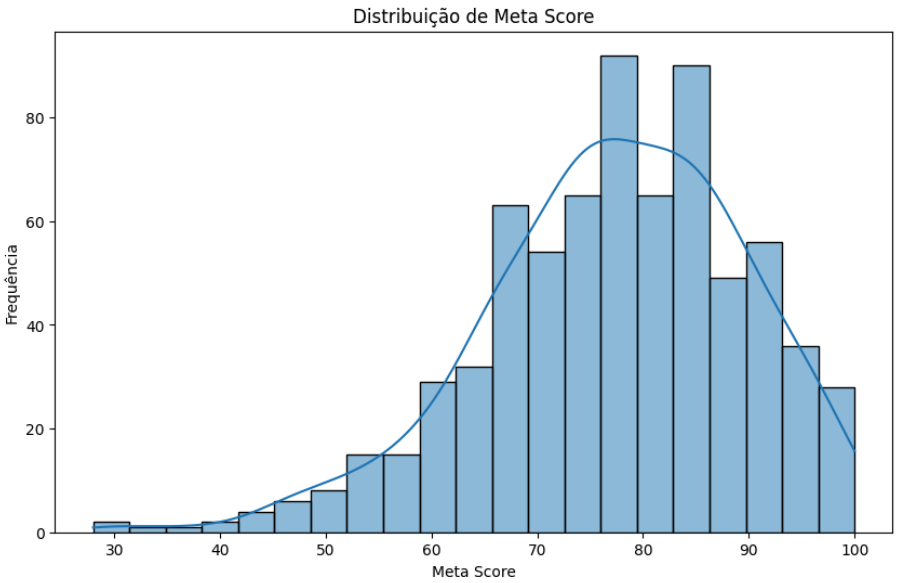

Imagem 04 - Gráfico que apresenta a frequência das avaliações no Metascore.

Para analisar especificamente os gêneros dos filmes do banco de dados, foi necessário “explodir” a coluna *Genre*. Isso foi necessário pois boa parte dos filmes analisados possuía mais de um gênero atrelado a ele, o que dificultava a análise como um todo. Algumas análises foram controversas.

Filmes que se encaixam no gênero *Film-Noir* tem a melhor média de avaliações no IMDB, porém são os que têm menor faturamento no geral. *Sci-Fi* e *Adventure* são, respectivamente, quarto e quinto lugares na média do IMDB por gênero, e são os que possuem maiores faturamentos. O gênero *Adventure* é o que possui maior faturamento, porém devemos notar que isso só aconteceu a partir do final da década de 90, tendo seu ápice em meados de 2010, período onde os filmes de super-heróis se tornaram mais populares.

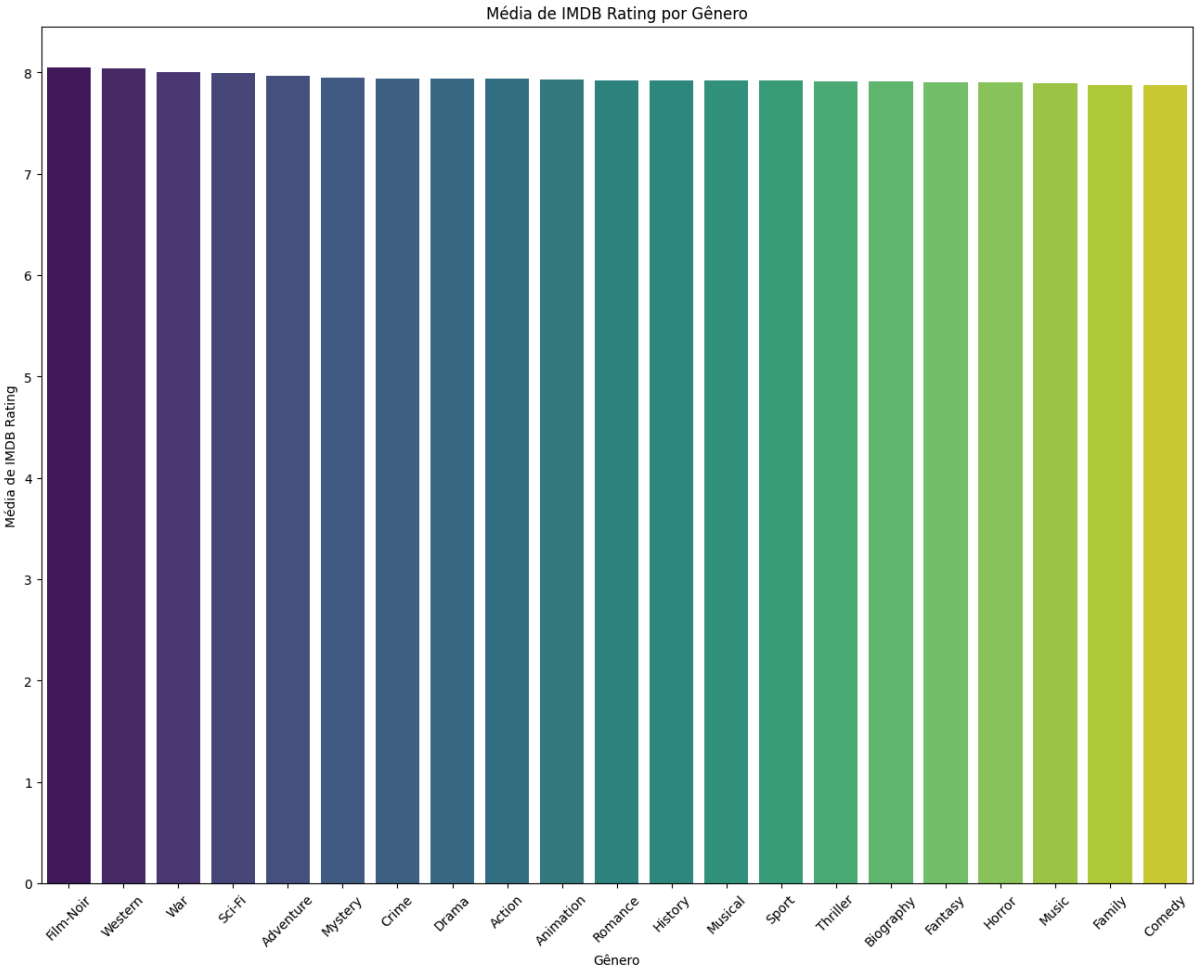

Imagem 05 - Gráfico que apresenta a média de IMDB por gênero.

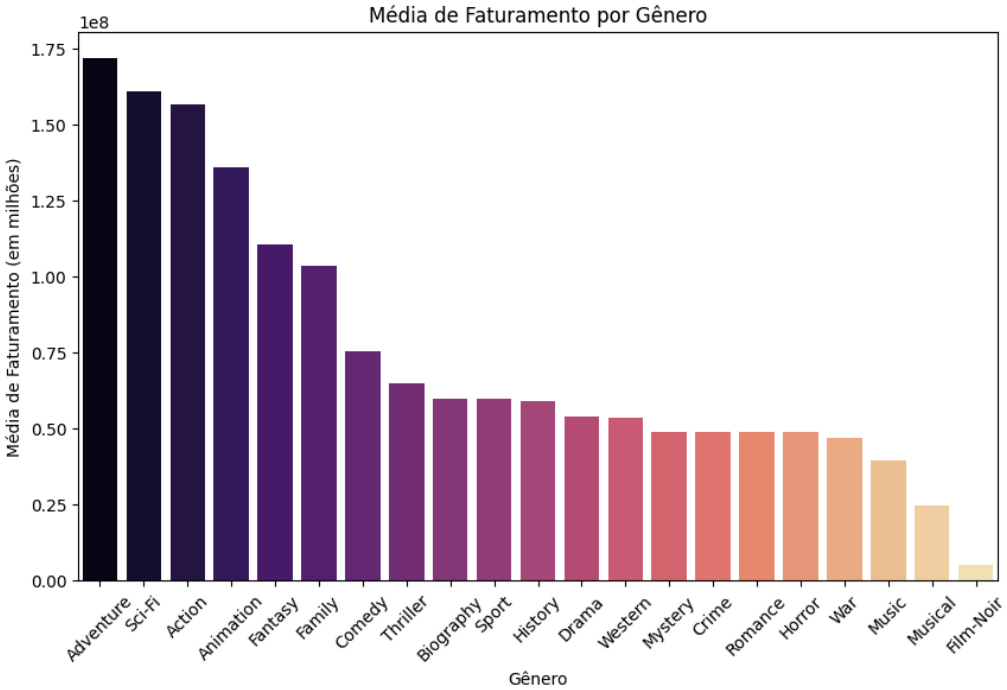

Imagem 06 - Gráfico que mede a média de faturamento por gênero.

Analisando os gêneros em comparação ao *Metascore*, o gênero dramático se destaca perante os demais gêneros. Outro fator relevante sobre o gênero é que praticamente metade dos filmes inseridos nessa lista se encaixam no gênero, mostrando grande destaque em comparação aos demais.

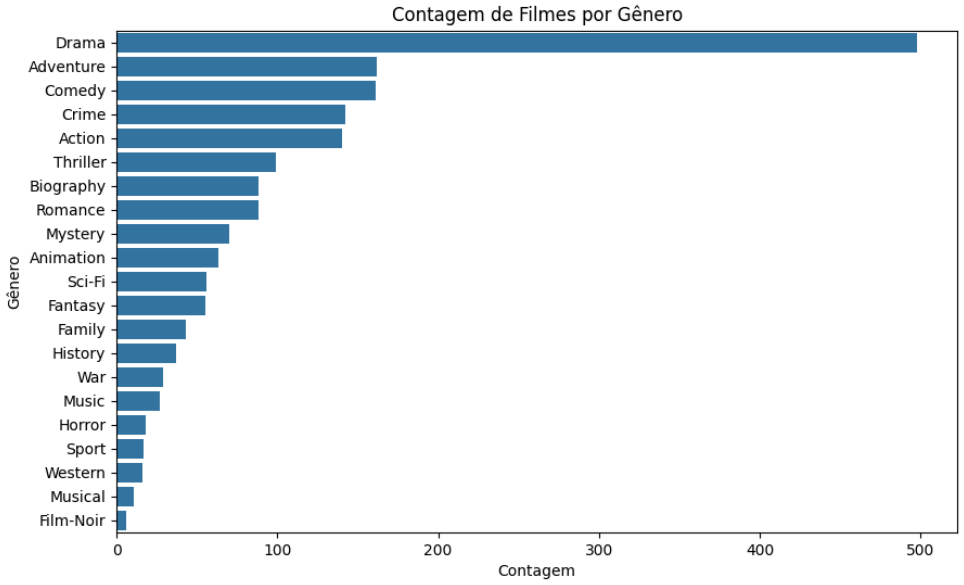

Imagem 07 - Gráfico que apresenta contagem de filmes do banco de dados por gênero.

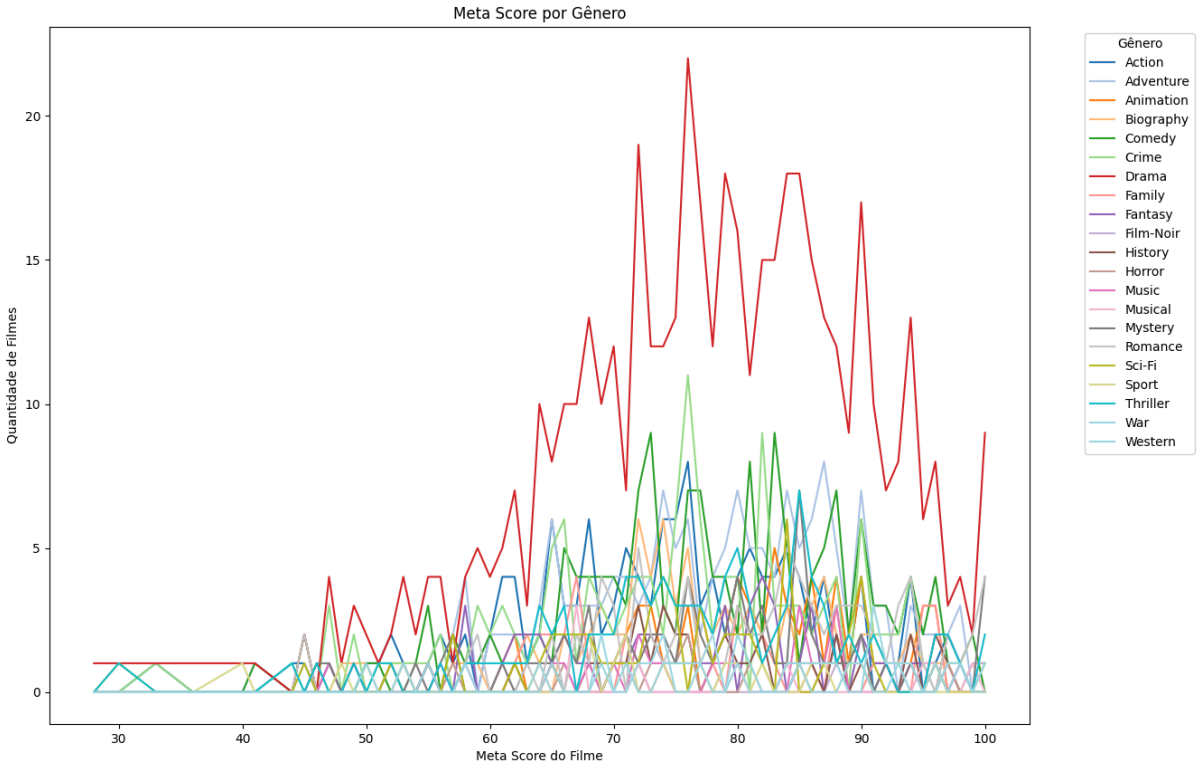

Imagem 08 - Gráfico que apresenta a variação no *Metascore* por gênero.

Passando para os diretores mencionados no banco de dados, e filtrando para os melhores avaliados no IMDB e com maior faturamento total, percebemos que o gênero dramático também se destaca nos nomes que estão em ambas as listas. Nomes como Steven Spielberg, James Cameron e Christopher Nolan são famosos por dirigirem filmes desse gênero.

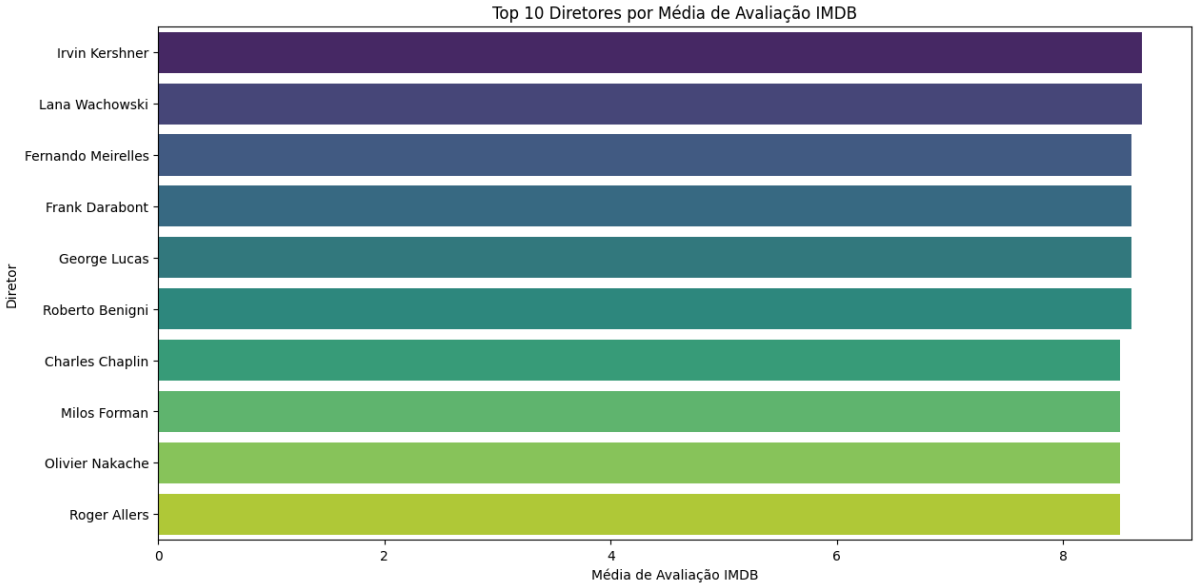

Imagem 09 - Gráfico exibindo os dez diretores que possuem as melhores médias de avaliação no IMDB

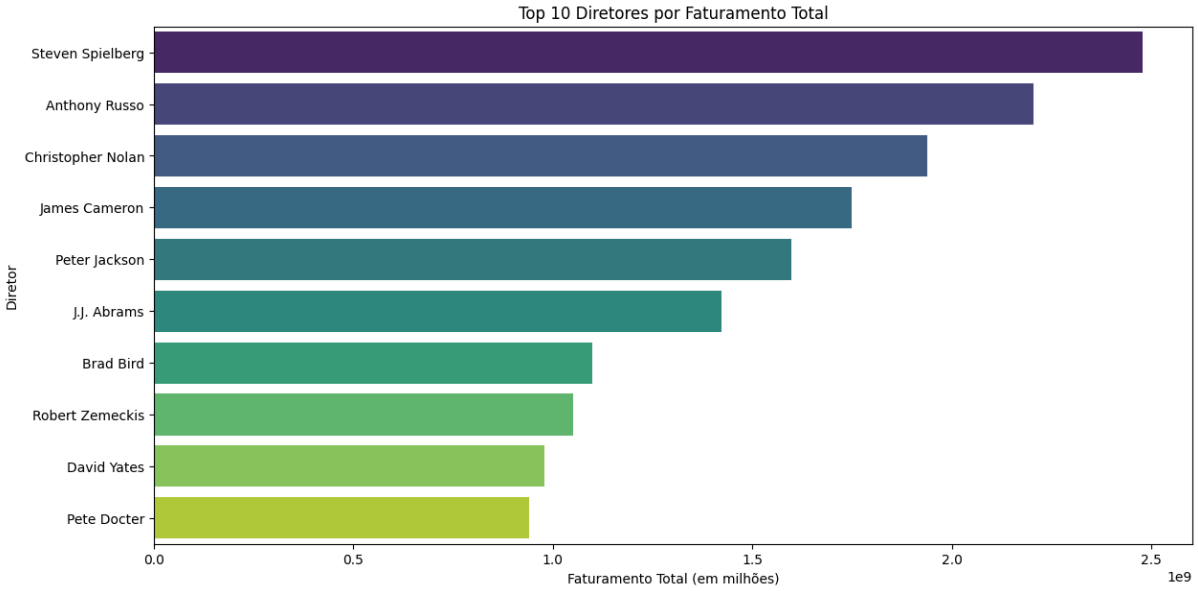

Imagem 10 - Índice de faturamento total por diretor de acordo com o banco de dados.

Em contrapartida, além do drama, diretores de filmes de ação, aventura e *sci-fi* se destacam com maiores faturamentos por obra. Como mencionado antes, muito desse mérito vem do *boom* ocorrido nas últimas décadas por conta de filmes de super-herois.

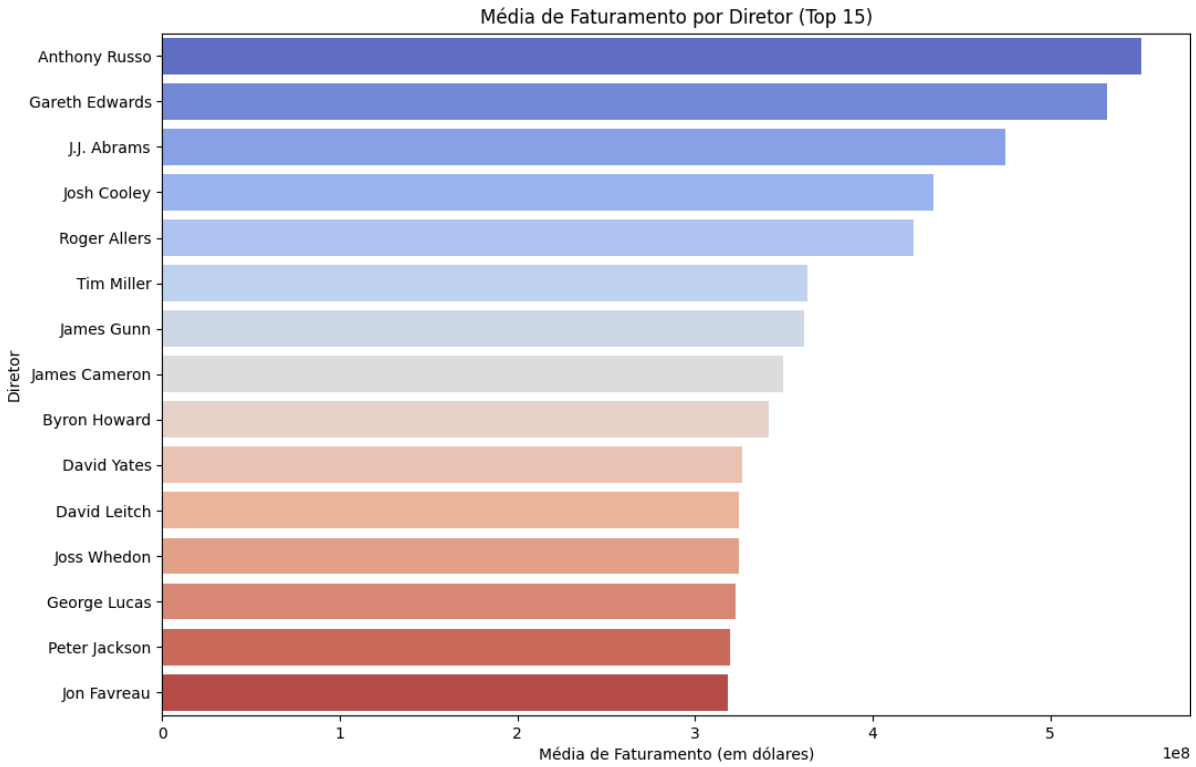

Imagem 11 - Gráfico que apresenta os 15 diretores com melhor faturamento por filme

A partir das análises feitas com os dados fornecidos, é possível concluir que o próximo filme produzido pela *PProductions* deve ser do gênero **DRAMA**.

Dos 20 filmes melhores cotados no dataset fornecido, 15 se encaixam no gênero dramático, possuindo alto faturamento na sua comercialização. Além disso, o site *Cloudwards*, especializado em análises de serviços de tecnologia, fez um levantamento de que esse é o segmento mais promissor nesse ano. Isso vai de encontro com o fato de que a maioria dos filmes que são produzidos e que se destacam nas avaliações se encaixam nesse gênero. Levando em consideração o fator faturamento, mesmo com oscilações, o gênero consegue manter regularidade durante o passar dos anos, estando em alta desde o final da última década.

QUESTIONAMENTOS COMPLEMENTARES

Alguns questionamentos extras foram feitos como parte deste desafio. Todos são pertinentes à temática de dados e muitos deles estão diretamente relacionados com a análise exploratória feita acima.

1. **QUESTIONAMENTOS GERAIS**

   a. **Qual filme você recomendaria para uma pessoa que você não conhece?**

   Não tenho como dar uma resposta exata para essa pergunta. Para poder recomendar um filme para uma pessoa que não conheço, eu preciso entender um poucos dos gostos dela. Saber qual gênero prefere (ou quais não gosta), se não tem problema com duração do filme ou período em que foi feito, entre outros fatores. Somente após ter essas informações é que me sentiria mais seguro em fazer a recomendação de um filme.

   b. **Quais são os principais fatores que estão relacionados com alta expectativa de faturamento de um filme?**

   Atualmente, os principais fatores relacionados à alta expectativa de faturamento são os principais artistas envolvidos na produção assim como o diretor responsável pela película. Nomes renomados tendem a gerar grandes investimentos, assim como geram grandes promoções de filmes, o que leva a bons faturamentos.

   c. **Quais insights podem ser tirados com a coluna *Overview?* É possível inferir o gênero do filme a partir dessa coluna?**

   A coluna *Overview* mostra uma breve sinopse do filme em questão, sem detalhar ao máximo o conteúdo do filme, porém mostrando ao leitor o assunto de maneira bem sucinta, já deixando o mesmo inteirado sobre o que pode vir a assistir. Em alguns casos, é sim possível inferir o gênero do filme a partir dessa informação. Entretanto, a grande maioria dos filmes não se enquadra em apenas um único gênero e isso acaba deixando um pouco vago na hora de identificar os outros possíveis gêneros. No geral, tudo vai depender de como essa sinopse foi apresentada ao leitor.

2. **QUESTIONAMENTOS ESPECÍFICOS**

   a. **Explique como você faria a previsão da nota do imdb a partir dos dados. Quais variáveis e/ou suas transformações você utilizou e por quê?**

   As únicas variáveis que podem ser descartadas são *Unnamed: 0*, *Series_Title* e *Overview*, pois todas possuem informações que não são relevantes para as previsões solicitadas. Todas as demais podem ser utilizadas. As variáveis categóricas (*Released_Year*, *Runtime*, *Certificate*, *Genre*, *Director*, *Star1*, *Star2*, *Star3*, *Star4*) serão transformadas para que suas informações possam ser utilizadas na hora da modelagem. Utilizar a técnica *One Hot Encoder* foi a

escolha mais simples e adequada para obter melhores resultados, sem colocar pesos entre os valores de cada categoria e por ser compatível com o modelo de treinamento selecionado.

b. **Qual tipo de problema estamos resolvendo (regressão, classificação)?**

É um problema do tipo regressão, pois essa é uma variável contínua, ou seja, uma variável que pode pode assumir um número infinito de valores dentro de um intervalo especificado no contexto que estamos analisando, englobando tanto números inteiros como números decimais.

c. **Qual modelo melhor se aproxima dos dados e quais seus prós e contras?**

O melhor modelo seria o de **Regressão Linear**, que é simples de implementar e interpretar, indicado para esse tipo de problemática. É um modelo de fácil interpretação. Todavia, esse modelo pode não capturar relações complexas.

d. **Qual medida de performance do modelo foi escolhida e por quê?**

A verificação da performance pode ser feita através do **MAE (mean absolute error)**. Não é a única abordagem possível, porém é uma abordagem simples que avalia as previsões e os valores reais e trata os erros de maneira linear e que gera uma medida clara da variação média de erro do modelo em questão.

e. **Supondo um filme com as seguintes características:**

```
{'Series_Title': 'The Shawshank Redemption',
 'Released_Year': '1994',
 'Certificate': 'A',
 'Runtime': '142 min',
 'Genre': 'Drama',
 'Overview': 'Two imprisoned men bond over a number of years, finding solace and eventual redemption through acts of common decency.',
 'Meta_score': 80.0,
 'Director': 'Frank Darabont',
 'Star1': 'Tim Robbins',
 'Star2': 'Morgan Freeman',
 'Star3': 'Bob Gunton',
 'Star4': 'William Sadler',
 'No_of_Votes': 2343110,
 'Gross': '28,341,469'}
```

Qual seria a nota do IMDB?

Aplicando o modelo de *machine learning* pensado para essa coluna, o valor aproximado do IMDB desse filme seria de 9,58.

CONCLUSÃO

A Análise Exploratória de Dados (EDA) realizada sobre o banco de dados fornecido proporcionou insights valiosos sobre diversos aspectos da indústria do cinema. Através do exame detalhado de variáveis como ano de lançamento, classificação etária, gêneros, avaliações, diretores, elenco e faturamento, foi possível identificar padrões, tendências e fatores que influenciam o sucesso dos filmes.

Os insights obtidos através deste relatório podem orientar decisões estratégicas em várias frentes, incluindo o desenvolvimento de novos filmes, estratégias de marketing, e a escolha de equipes de produção. A compreensão das preferências do público e das tendências da indústria é crucial para produzir conteúdo que ressoe com a audiência e seja financeiramente viável.

Recomenda-se, para projetos futuros, a continuidade da análise com dados adicionais e o uso de técnicas mais avançadas, para aprofundar ainda mais a compreensão dos fatores que influenciam o sucesso no cinema. A integração de feedback contínuo e dados em tempo real pode também aprimorar a precisão das previsões e a eficácia das estratégias adotadas.

A análise exploratória feita aqui é um passo fundamental no entendimento dos dados e na formulação de estratégias informadas. A indústria do cinema é dinâmica e competitiva, e a capacidade de utilizar dados de forma eficaz pode ser um diferencial significativo para o sucesso.